




Разбираем ПЗ 1




Жизненный цикл моделей ML



**Межотраслевой стандарт
интеллектуального анализа данных**

CRISP-DM: Cross Industry Standard
Process for Data Mining (1999)



Понимание бизнес-целей
(Business Understanding)

Понимание данных
(Data Understanding)

Подготовка данных
(Data Preparation)

Моделирование
(Modeling)

Оценка
(Evaluation)

Внедрение
(Deployment)

МЕТРИКИ КАЧЕСТВА



Интервьюер: "В чем ваша самая сильная сторона?"

Эксперт по МО: "Я эксперт в машинном обучении."

Интервьюер: Сколько будет $6 + 10$?

Эксперт по МО: Ноль.

Интервьюер: Это даже близко не так! Это 16!


Эксперт по МО: Ладно, будет 16.

Интервьюер: Сколько будет $10 + 20$?

Эксперт по МО: Будет 16.

Машинное обучение — это класс методов для решения задач искусственного интеллекта. Алгоритмы машинного обучения **распознают паттерны в больших массивах данных** и используют их для самообучения. *(и косячат...)*

$$Y \approx f(X)$$





$$Y_{real} \neq Y_{model} \rightarrow \Delta$$

Метрики в задачах регрессии:

- MAE (mean absolute error)
- MSE (mean squared error)
- RMSE (root mean squared error)
- R2 (коэффициент детерминации)

Метрики в задачах классификации:

- accuracy
- precision (точность)
- recall (полнота)
- F-мера
- AUC-ROC
- AUC-PR
- Logistic Loss

ПРАКТИКА. МЕТРИКИ



МО. Метрики_регрессии.ipynb



МО. Метрики классификации.ipynb



ПЗ1.Метрики.xlsx



<https://disk.yandex.ru/d/lsSrC2AfbbrVSw>



Регрессия

model	part	MAE	MSE	RMSE	R2
LinReg	test				
LinReg	train				
Polynomial Reg	test				
Polynomial Reg	train				

Бинарная классификация

model	part	Accuracy	Precision	Recall	F1-score	AUC ROC	AUC PR
DecisionTree	test						
DecisionTree	train						
GradientBoosting	test						
GradientBoosting	train						



Регрессия

model	part	MAE	MSE	RMSE	R2
LinReg	test	16.9925	416.4279	20.4066	0.9983
LinReg	train	16.8251	405.3586	20.1335	0.9984
Polynomial Reg	test	16.5620	402.9623	20.0739	0.9983
Polynomial Reg	train	17.0380	417.0896	20.4228	0.9982

Бинарная классификация

model	part	Accuracy	Precision	Recall	F1-score	AUC ROC	AUC PR
DecisionTree	test	0.5151	0.5347	0.5233	0.5289	0.5168	0.5342
DecisionTree	train	0.4957	0.5087	0.4939	0.5012	0.4832	0.4944
GradientBoosting	test	0.4715	0.4777	0.4711	0.4744	0.4727	0.4879
GradientBoosting	train	0.4984	0.5265	0.4768	0.5004	0.5108	0.5431

ПРАКТИКА. МЕТРИКИ



Метрики_ПЗ1.ipynb




ПЗ1.Метрики.xlsx



<https://disk.yandex.ru/d/aBVtWCsviBIXvQ>



Линейная регрессия




Жизненный цикл моделей ML



**Межотраслевой стандарт
интеллектуального анализа данных**

CRISP-DM: Cross Industry Standard
Process for Data Mining (1999)



Понимание бизнес-целей
(Business Understanding)

Понимание данных
(Data Understanding)

Подготовка данных
(Data Preparation)

Моделирование
(Modeling)

Оценка
(Evaluation)


Внедрение
(Deployment)

Жизненный цикл моделей ML



**Межотраслевой стандарт
интеллектуального анализа данных**

CRISP-DM: Cross Industry Standard
Process for Data Mining (1999)



Понимание бизнес-целей
(Business Understanding)

Понимание данных
(Data Understanding)

Подготовка данных
(Data Preparation)


**Моделирование
(Modeling)**

Оценка
(Evaluation)


Внедрение
(Deployment)




**Через две точки на плоскости
можно провести прямую и
только одну**



**А если точек на
плоскости – три и более?**









ЗАДАЧА РЕГРЕССИИ



Регрессия – предсказание непрерывной целевой переменной.

Для такой задачи хочется, чтобы наши модели предсказывали числа как можно ближе к истинным, чтобы отклонения реального значения и прогноза модели были минимальными.

ЛИНЕЙНАЯ РЕГРЕССИЯ





Одномерная линейная регрессия

МЕТОД НАИМЕНЬШИХ КВАДРАТОВ

Дано:

1. Набор экспериментальных точек $(y_1, x_1), (y_2, x_2), \dots, (y_n, x_n)$
2. Линейная модель $y = a + bx$

Найти коэффициенты a и b



Одномерная линейная регрессия

МЕТОД НАИМЕНЬШИХ КВАДРАТОВ

Переопределённая система уравнений


$$\begin{cases} a + bx_1 = y_1 \\ a + bx_2 = y_2 \\ \dots \\ a + bx_n = y_n \end{cases}$$

В общем случае решения не имеет
(т.к. экспериментальные точки
обычно не ложатся в точности на
одну прямую)



Одномерная линейная регрессия

МЕТОД НАИМЕНЬШИХ КВАДРАТОВ





Одномерная линейная регрессия

МЕТОД НАИМЕНЬШИХ КВАДРАТОВ

Необходимость в приближенных методах

Метод наименьших квадратов (МНК)

Минимизация суммы квадратов отклонений RSS (Residual Sum of Squares)

$$RSS = \sum_i (y_i - (a + bx_i))^2$$

МЕТОД НАИМЕНЬШИХ КВАДРАТОВ

Аналитический метод



Метод заключается в минимизации суммы квадратов разностей между наблюдаемыми значениями и прогнозируемыми значениями. Таким образом, метод наименьших квадратов стремится минимизировать суммарные ошибки прогнозирования, чтобы получить наилучшую линейную модель

$$y = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n + \epsilon$$

y — целевая переменная, x_i — признаки, w_i — веса, ϵ — ошибка.

Найти вектор весов w , минимизирующий сумму квадратов ошибок (MSE):

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \rightarrow \min_w$$

МЕТОД НАИМЕНЬШИХ КВАДРАТОВ

Аналитический метод



Пусть $x^{(1)}, \dots, x^{(D)}$ – столбцы матрицы X , то есть столбцы признаков. Тогда

$$Xw = w_1x^{(1)} + \dots + w_Dx^{(D)}$$

и задачу регрессии можно сформулировать следующим образом: *найти линейную комбинацию столбцов $x^{(1)}, \dots, x^{(D)}$, которая наилучшим способом приближает столбец y по евклидовой норме – то есть найти проекцию вектора y на подпространство, образованное векторами $x^{(1)}, \dots, x^{(D)}$.*

$$X^T(y - Xw) = 0 \qquad w = (X^T X)^{-1} X^T y$$

Подробнее – [Яндекс.Хендбук. Линейные модели](#)

Одномерная линейная регрессия



КОЭФФИЦИЕНТЫ

Минимизируемая функция

$$RSS = \sum_i (y_i - (a + bx_i))^2$$

Результат расчёта

$$\begin{cases} a = \bar{y} - b\bar{x} \\ b = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - (\bar{x})^2} \end{cases}$$

Одномерная линейная регрессия



КОЭФФИЦИЕНТЫ

$$RSS = \sum_i (y_i - \hat{y}_i)^2$$

residual sum of squares (сумма квадратов отклонений)

$$TSS = \sum_i (y_i - \bar{y})^2$$

total sum of squares (общая сумма квадратов)

$$ESS = \sum_i (\hat{y}_i - \bar{y})^2$$

explained sum of squares
(объяснённая сумма квадратов)

Коэффициент детерминации R^2

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2} = 1 - \frac{RSS}{TSS} = \frac{ESS}{TSS}$$

$$RSS + ESS = TSS$$

Линейная регрессия: доверительные интервалы

$$y = a + bx$$

$$s_e^2 = \frac{\sum_i (y_i - \hat{y}_i)^2}{N - 2} = \frac{RSS}{N - 2}$$

Доверительные интервалы коэффициентов регрессии

$$s_a^2 = s_e^2 \left[\frac{1}{n} + \frac{(\bar{x})^2}{\sum_i (x_i - \bar{x})^2} \right]$$

$$\Delta a = s_a \cdot t(\alpha; N - 2)$$

$$s_b^2 = \frac{s_e^2}{\sum_i (x_i - \bar{x})^2}$$

$$\Delta b = s_b \cdot t(\alpha; N - 2)$$

Доверительные интервалы предсказанных значений

$$s_{\hat{y}_j}^2 = s_e^2 \left[\frac{1}{n} + \frac{(x_j - \bar{x})^2}{\sum_i (x_i - \bar{x})^2} \right]$$

$$\Delta \hat{y}_i = s_{\hat{y}_i} \cdot t(\alpha; N - 2)$$

Одномерная линейная регрессия



КРИТЕРИЙ ФИШЕРА (F-ТЕСТ)

Шаг 1. Найти $F_{\text{эмп}}$

$$F_{\text{эмп}} = \frac{R^2}{1 - R^2} \cdot \frac{f_2}{f_1}$$

f_2 - число степеней свободы для данных ($N - 2$ для $y = a + bx$)

f_1 - число независимых коэффициентов (1 для $y = a + bx$)

Откуда взята формула?

$$\frac{ESS/f_1}{RSS/f_2} = \frac{ESS/TSS}{RSS/TSS} \cdot \frac{f_2}{f_1} = \frac{R^2}{1 - R^2} \cdot \frac{f_2}{f_1}$$

Шаг 2. Сравнить с табличным значением квантиля

Если $F_{\text{эмп}} \sim F(f_1; f_2)$, то зависимость статистически незначима

На практике:

Если $F_{\text{эмп}} < F(\alpha; f_1; f_2)$
(т.е. сравнивают с табличным значением квантиля)

Одномерная линейная регрессия



КРИТЕРИЙ ФИШЕРА (F-ТЕСТ)

Пример: $R^2=0.667$, $N=11$, аппроксимация $y = a + bx$

$$F_{emp} = \frac{R^2}{1 - R^2} \cdot \frac{f_2}{f_1}$$

$$F(0.95, 1, 9) = 5.12$$



Регрессия значима

$$F_{emp} = \frac{0.667}{0.333} \cdot \frac{9}{1} = 18$$

Одномерная линейная регрессия



MS EXCEL

Способ 1. Линия тренда на графике

1. Построить точечный график по имеющимся данным вида (y_i, x_i)
2. Щелкнуть правой кнопкой мыши на серии точек и выбрать «добавить линию тренда»
3. Отметить флажками нужные опции (вид аппроксимирующей функции, показывать ли уравнение на диаграмме, показывать ли R^2 и т.п.)

Наглядно, но не проводятся F-тест и оценка доверительных интервалов коэффициентов регрессии


Файл Главная **Вставка** Разметка страницы Формулы Данные Рецензирование Вид Справка

Сводная таблица Рекомендуемые сводные таблицы Таблица Рисунки Фигуры SmartArt Снимок Получить надстройки Мои надстройки Рекоменд. диаграммы Диаграммы Карты Сводная диаграмма 3D-карта Обзоры График Гистограмма Выигрыш/проигрыш Срез Временная шкала Ссылка Примечание Текст Уравнение Символ

Примечания Поделиться

AB32

	Х		Y	
	Количество собственных легковых автомобилей на 1 000 человек		Количество эксплуатационных автобусов общего пользования на 100 000 человек населения	
2	Год			
3	2000	130.5	74	
4	2001	137.2	74	
5	2002	145.8	70	
6	2003	153.0	64	
7	2004	158.9	60	
8	2005	168.4	55	
9	2006	177.0	51	
10	2007	194.4	48	
11	2008	212.3	45	
12	2009	219.4	45	
13	2010	228.4	110	
14	2011	242.0	116	
15	2012	257.5	119	
16	2013	273.1	116	
17	2014	283.3	114	
18	2015	288.8	120	
19	2016	294.0	117	
20	2017	305.0	116	
21	2018	309.1	114	
22	2019	315.5	114	
23	2020	321.0	110	



Одномерная линейная регрессия



MS EXCEL

Способ 2. Использование пакета анализа данных


1. Выбрать вкладку данные, щелкнуть по пункту меню «анализ данных»
2. Из предлагаемых опций выбрать регрессию
3. Указать входные данные и изучить результат

Нагляден, содержит F-тест и оценку доверительных интервалов коэффициентов регрессии

Одномерная линейная регрессия

MS EXCEL

Способ 2. Использование пакета анализа данных



Регрессия

Входные данные

Входной интервал Y:

Входной интервал X:

☒ Метки ☐ Константа - ноль

☒ Уровень надежности: %

Параметры вывода

☐ Выходной интервал:

☒ Новый рабочий лист:

☐ Новая рабочая книга

Остатки

☒ Остатки ☒ График остатков

☒ Стандартизованные остатки ☒ График подбора

Нормальная вероятность

☒ График нормальной вероятности

ОК Отмена Справка

Одномерная линейная регрессия



MS EXCEL

Способ 3. Вручную

Использовать функции MS Excel вроде КОВАР, ДИСП, СРЗНАЧ, СУММ, КОРРЕЛ и т.п.

На практике способ не удобен, но полезен для понимания сути происходящего

Одномерная линейная регрессия



MS EXCEL

Способ 3. Вручную

a													
0.355995674		=КОРРЕЛ(В3:В23;С3:С23)*(СТАНДОТКЛОН.В(С3:С23)/СТАНДОТКЛОН.В(В3:В23))											
0.355995674		=КОВАРИАЦИЯ.В(В3:В23;С3:С23)/ДИСП.В(В3:В23)											
b													
6.589438596		=СРЗНАЧ(С3:С23)-G6*СРЗНАЧ(В3:В23)											

Одномерная линейная регрессия



MS EXCEL

Способ 4. Вручную

Использовать функции MS Excel **ЛИНЕЙН**

Нагляден, содержит F-тест + сразу актуализируется при изменении данных

Автосохранение

ПРИМЕР.xlsx • Сохранено

Поиск (Alt+Y)

Nikita Atamasov

Главная

Вставка

Разметка страницы

Формулы

Данные

Рецензирование

Вид

Справка

Отмена

Буфер обмена

Вставить

Вырезать

Копировать

Формат по образцу

Шрифт

Выравнивание

Число

Стили

Ячейки

Редактирование

E20

fx

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1		X	Y														
		Количество собственных легковых автомобилей на 1 000 человек	Количество эксплуатационных автобусов общего пользования на 100 000 человек населения														
2	Год																
3	2000	130.5	74														
4	2001	137.2	74														
5	2002	145.8	70														
6	2003	153.0	64														
7	2004	158.9	60														
8	2005	168.4	55														
9	2006	177.0	51														
10	2007	194.4	48														
11	2008	212.3	45														
12	2009	219.4	45														
13	2010	228.4	110														
14	2011	242.0	116														
15	2012	257.5	119														
16	2013	273.1	116														
17	2014	283.3	114														
18	2015	288.8	120														
19	2016	294.0	117														
20	2017	305.0	116														
21	2018	309.1	114														
22	2019	315.5	114														
23	2020	321.0	110														
24																	
25																	
26																	

=ЛИНЕЙН(С3:С23;В3:В23;1;1)

	A	B	C	D	E	F
1	m_n	m_{n-1}	$\dots$	m_2	m_1	b
2	se_n	se_{n-1}	$\dots$	se_2	se_1	se_b
3	r_2	se_y				
4	F	df				
5	ss_{reg}	ss_{resid}				

0.355995674

6.589438596

0.355995674

6.589438596

0.065922376

15.68817837

0.605501652

19.27570572

29.16243232

19

53.04687408

=K3*B3+L3

10835.38429

7059.503792

53.04687408

=ТЕНДЕНЦИЯ(С3:С23;В3:В23;130.5;1)

Данные

Линейная регрессия

Формулы

ЛИНЕЙН и ТЕНДЕНЦИЯ

Готово

Специальные возможности: проверьте рекомендации

85 %

Одномерная линейная регрессия

PYTHON



ЛИНЕЙНАЯ РЕГРЕССИЯ

Реализация в sklearn



Класс `LinearRegression` в библиотеке `scikit-learn` реализует обычный **метод наименьших квадратов (OLS)** для обучения линейной модели.

Основные параметры:

- `fit_intercept` – Добавляет свободный член (`intercept`) в модель. Если `False`, линия проходит через начало координат.
- `copy_X` – Если `True`, копирует входные данные, чтобы они не изменялись.
- `n_jobs` – Количество ядер CPU для параллельных вычислений (полезно для больших данных).
- `positive` – Если `True`, коэффициенты будут положительными

Основные методы:

- `fit(X, y)` – Обучение модели на данных `X` (признаки) и `y` (целевая переменная)
- `predict(X)` – Предсказание значений для новых данных `X`.
- `score(X, y)` – Возвращает коэффициент детерминации R^2

```

В [9]: 1 #Импортируем необходимые библиотеки
        2 import numpy
        3 import pandas as pd
        4 import matplotlib.pyplot as plt
        5
        6 from sklearn.linear_model import LinearRegression
        7 from sklearn.metrics import r2_score
        8
        9
       10 #Загрузка набора данных
       11 data = pd.read_excel("C:/WORK/МИИТ/Анализ данных в Excel/Лекции/Л4/ПРИМЕР.xlsx")
       12

```

В [2]: 1 data

Out[2]:

	Год	Количество собственных легковых автомобилей на 1 000 человек	Количество эксплуатационных автобусов общего пользования на 100 000 человек населения
0	2000	130.500000	74.249711
1	2001	137.200000	74.260578
2	2002	145.800000	69.710555
3	2003	153.000000	64.350234
4	2004	158.900000	60.010690
5	2005	168.400000	55.258928
6	2006	177.000000	50.517738
7	2007	194.400000	48.316071
8	2008	212.300000	45.094062
9	2009	219.400000	45.364707
10	2010	228.400000	110.000000

Одномерная линейная регрессия

PYTHON



```
В [3]: 1 #Разделим набор данных так, чтобы у нас получилась задача регрессии
        2 X = data.drop(['Год', 'Количество эксплуатационных автобусов общего пользования на 100 000 человек населения'], axis=1)
        3 Y = data.drop(['Год', 'Количество собственных легковых автомобилей на 1 000 человек'], axis=1)
```

```
В [4]: 1 #Линейная регрессия
        2 model_linreg = LinearRegression().fit(X, numpy.ravel(Y))
```

Одномерная линейная регрессия



PYTHON

```
B [5]: 1 model_linreg.coef_[0]
```

```
Out[5]: 0.35599567421713435
```

```
B [6]: 1 model_linreg.intercept_
```

```
Out[6]: 6.589438595574791
```

0.35599567421713435

6.589438595574791

Одномерная линейная регрессия



PYTHON

В [7]:

```
1  #Оценим получившиеся регрессии
2
3  #Применим модель, чтобы посчитать модельные результаты
4  #Обучающая выборка
5
6  Y_linreg_train=model_linreg.predict(X)
7
8  #R2
9  R2_linreg_train=r2_score(Y, Y_linreg_train)
10
11 print('R2 Линейная регрессия. Обучение '+ str(R2_linreg_train))
```

R2 Линейная регрессия. Обучение 0.6055016516766749


0.6055016516766749


Одномерная линейная регрессия



PYTHON

```
: 1 #Визуализация зависимости прогноза и факта
  2
  3 #Линейная регрессия
  4 plt.scatter(Y, Y_linreg_train, color='gold')
  5 plt.title('Линейная регрессия. Факт и прогноз на обучающей выборке')
  6 plt.xlabel('Реальное значение')
  7 plt.ylabel('Прогнозное значение')
  8 plt.show()
```







```
B [22]: 1 model_linreg.coef_
```

```
Out[22]: array([ 5.42414194e-03,  4.58114821e-01, -6.02955536e-03,  3.21779991e-05,  
               -7.84611206e-08,  7.23521811e-11])
```

```
B [23]: 1 model_linreg.intercept_
```

```
Out[23]: -1047.58479719329
```

```
B [24]: 1 #Оценим получившиеся регрессии  
        2  
        3 #Применим модель, чтобы посчитать модельные результаты  
        4 #Обучающая выборка  
        5  
        6 Y_linreg_train=model_linreg.predict(X)  
        7  
        8 #R2  
        9 R2_linreg_train=r2_score(Y, Y_linreg_train)  
       10  
       11 print('R2 Линейная регрессия. Обучение '+ str(R2_linreg_train))
```


R2 Линейная регрессия. Обучение 0.8787044816178574

0.8787044816178574

```


1 #Линейная регрессия
2 plt.plot(X['Количество собственных легковых автомобилей на 1 000 человек'], Y_linreg_train, color='gold', marker='o')
3 plt.plot(X['Количество собственных легковых автомобилей на 1 000 человек'], Y, color='blue', marker='o')
4 plt.title('Полином')
5 plt.xlabel('Автомобили')
6 plt.ylabel('Автобусы')
7 plt.show()

```



```
В [25]: 1 #Визуализация зависимости прогноза и факта
        2
        3 #Линейная регрессия
        4 plt.scatter(Y, Y_linreg_train, color='gold')
        5 plt.title('Линейная регрессия. Факт и прогноз на обучающей выборке')
        6 plt.xlabel('Реальное значение')
        7 plt.ylabel('Прогнозное значение')
        8 plt.show()
```

Линейная регрессия. Факт и прогноз на обучающей выборке



Многомерная линейная регрессия



Исходные данные


Точки в $(k+1)$ – мерном пространстве
 $(y_i, x_{i1}, \dots, x_{ik})$



Аппроксимирующая функция

$$y = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}$$

β – параметры модели



Система уравнений (переопределённая):

$$\begin{cases} \beta_1 x_{11} + \beta_2 x_{12} + \dots + \beta_k x_{1k} = y_1 \\ \beta_1 x_{21} + \beta_2 x_{22} + \dots + \beta_k x_{2k} = y_2 \\ \dots \\ \beta_1 x_{n1} + \beta_2 x_{n2} + \dots + \beta_k x_{nk} = y_n \end{cases}$$

Система в матричном виде: $X\beta = y$

$$X = \begin{bmatrix} x_{11} & \dots & x_{1k} \\ \vdots & \ddots & \vdots \\ x_{n1} & \dots & x_{nk} \end{bmatrix}; y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}; \beta = \begin{pmatrix} \beta_1 \\ \vdots \\ \beta_n \end{pmatrix}$$

ПРАКТИКА. ЛИНЕЙНАЯ РЕГРЕССИЯ



1. Есть данные (файл xlsx – листы LinReg1 и LinReg2)
2. Построить линейную регрессию рассмотренными методами (Excel, Python)
3. Посчитать метрики как в ПЗ 1 для регрессии



<https://disk.yandex.ru/d/aBVtWCsviBIXvQ>