




Разбираем ПЗ 2



ПРАКТИКА. ЛИНЕЙНАЯ РЕГРЕССИЯ



1. Есть данные (файл xlsx – листы LinReg1 и LinReg2)
2. Построить линейную регрессию рассмотренными методами (Excel, Python)
3. Посчитать метрики как в ПЗ 1 для регрессии



<https://disk.yandex.ru/d/aBVtWCsviBIXvQ>

ПРАКТИКА. ЛИНЕЙНАЯ РЕГРЕССИЯ



Лист	b1	b0	MAE	MSE	RMSE	R2
LinReg1						
LinReg2						

ПРАКТИКА. ЛИНЕЙНАЯ РЕГРЕССИЯ



Лист	b1	b0	MAE	MSE	RMSE	R2
LinReg1	9.8100	0.0000	0.0000	0.0000	0.0000	1.0000
LinReg2	0.0623	13.6392	2.7281	11.6920	3.4194	0.7632


ПРАКТИКА. ЛИНЕЙНАЯ РЕГРЕССИЯ



The distance between Uranus and Saturn

correlates with

UFO sightings in Texas




••• The average distance between Uranus and Saturn as measured on the first day of each month · Source: Cacculated using Astropy

— UFO sightings reported in Texas · Source: National UFO Reporting Center

1975-2021, $r=0.874$, $r^2=0.763$, $p<0.01$ · tylervigen.com/spurious/correlation/1607




Кластеризация



Жизненный цикл моделей ML

**Межотраслевой стандарт
интеллектуального анализа данных**

CRISP-DM: Cross Industry Standard
Process for Data Mining (1999)



Понимание бизнес-целей
(Business Understanding)

Понимание данных
(Data Understanding)

Подготовка данных
(Data Preparation)

Моделирование
(Modeling)

Оценка
(Evaluation)

Внедрение
(Deployment)

КЛАССИЧЕСКОЕ МАШИННОЕ ОБУЧЕНИЕ

МАШИННОЕ ОБУЧЕНИЕ

ДАННЫЕ НИКАК НЕ РАЗМЕЧЕНЫ

КЛАССИКА


ДАННЫЕ КАТЕГОРИЗИРОВАНЫ

БЕЗ УЧИТЕЛЯ

С УЧИТЕЛЕМ

КЛАСТЕРИЗАЦИЯ

«РАЗЛОЖИ ПОХОЖИЕ ВЕЩИ
ПО КУЧКАМ»




АССОЦИАТИВНЫЕ ПРАВИЛА

«ВЫЯВИ
ПОСЛЕДОВАТЕЛЬНОСТЬ»



ANOMALY DETECTION


«ЧТО ТУТ НЕ ТАК?»



Anomaly Detection: Why Most Businesses Get It Wrong


КЛАССИФИКАЦИЯ

«РАЗЛОЖИ ФУТБОЛКИ ПО
ЦВЕТУ»



РЕГРЕССИЯ

«РАЗЛОЖИ ОБУВЬ ПО
РАЗМЕРУ»



ЗАДАЧА: АНАЛИЗ ГЕОДАННЫХ



Представим, что вы работаете в Яндекс. Такси и участвуете в разработке пикап-поинтов (наиболее удобных точек вызова такси, подсвечиваемых в приложении). У вас есть геоданные пользователей (собранные приложением).


Что будете делать?

ЗАДАЧА: АНАЛИЗ ГЕОДАННЫХ




Пример данных всего нескольких пользователей на локации аэропорт Внуково.

А у нас тысячи пользователей в локации, каждый из которых еще и меняет свое местоположение + GPS координаты известны с некоторой погрешностью



Пример взят из [учебника по машинному обучению Яндекс](#)

ЗАДАЧА: ОТОБРАЖЕНИЕ МНОЖЕСТВО ФОТОГРАФИЙ НА КАРТЕ



КЛАСТЕРИЗАЦИЯ



Задача кластеризации состоит в разделении исследуемого множества объектов на группы «похожих» объектов, называемых кластерами.

Решение задачи кластеризации называют **кластерным анализом**.




ДЛЯ ЧЕГО ПРИМЕНЯЕТСЯ КЛАСТЕРИЗАЦИЯ?




- Упростить дальнейшую обработку данных,
разбить множество объектов на группы схожих объектов чтобы работать с каждой группой в отдельности (задачи классификации, регрессии, прогнозирования).
- Сократить объём хранимых данных,
оставив по одному представителю от каждого кластера (задачи сжатия данных).
- Выделить нетипичные объекты,
которые не подходят ни к одному из кластеров (задачи одноклассовой классификации).
- Построить иерархию множества объектов
(задачи таксономии).




КАКИЕ ВСТРЕЧАЮТСЯ РАСПРЕДЕЛЕНИЯ




- Выраженные кластеры




- Ленточные кластеры




- Сферические кластеры



- Кластеры с «перемычками»



- Зашумлённые кластеры



- Перекрывающиеся кластеры

КЛАСТЕРНЫЙ АНАЛИЗ В ТЕОРИИ



КЛАСТЕРНЫЙ АНАЛИЗ НА ПРАКТИКЕ



Ключевой вопрос



- Для группировки объектов мы должны определить:
 - какие характеристики объектов будем использовать для группировки
 - что будет являться критерием их схожести
 - какое количество кластеров нас удовлетворит (необходимо выбрать / выработать критерии качества кластеризации)



Евклидово расстояние



Самой распространенной мерой для определения расстояния между двумя точками на плоскости, образованной координатными осями x и y , является **Евклидова мера**:

Квадрат евклидова расстояния (Squared Euclidian distance)

$$d(X, Y) = \sum_{i=1}^m (X_i - Y_i)^2$$

На расстояния могут сильно влиять различия между осями, по координатам которых вычисляются эти расстояния. Например, если одна из осей измерена в сантиметрах, а потом переведена в миллиметры, то окончательное евклидово расстояние (или квадрат евклидова расстояния), вычисляемое по координатам, сильно изменится, и, как следствие, результаты кластерного анализа могут сильно отличаться от предыдущих.


ВЫБОР СПОСОБА КЛАСТЕРИЗАЦИИ





ВЫБОР СПОСОБА КЛАСТЕРИЗАЦИИ



ПРИМЕР КЛАСТЕРИЗАЦИИ К – СРЕДНИХ



ПРИМЕР КЛАСТЕРИЗАЦИИ К – СРЕДНИХ



Выбор числа кластеров




Кажется, что правильным был бы критерий минимальности суммы квадратов расстояний от точек до центроидов кластеров, к которым они относятся.

$$J(C) = \sum_{k=1}^K \sum_{i \in C_k} ||x_i - \mu_k|| \rightarrow \min_C,$$

, здесь C – множество кластеров мощности K , μ_k – центроид кластера C_k .

Но вот незадача: если пользоваться таким критерием, то количество кластеров должно совпадать с количеством наблюдений.


Выбор числа кластеров



Для решения этого вопроса (выбора числа кластеров) часто пользуются такой эвристикой: выбирают то число кластеров, начиная с которого описанный функционал $J(C)$ падает "уже не так быстро". Или более формально:

$$D(k) = \frac{|J(C_k) - J(C_{k+1})|}{|J(C_{k-1}) - J(C_k)|} \rightarrow \min_k$$

Кластеризация DBSCAN



Это алгоритм кластеризации, основанный на плотности — если дан набор точек в некотором пространстве, алгоритм группирует вместе точки, которые тесно расположенные друг с другом, помечая как выбросы (шум) точки, которые находятся одиноко в областях с малой плотностью.

Шаги алгоритма



- Пометить все точки, как основные, пограничные или шумовые
- Отбросить точки шума
- Соединить все основные точки, находящиеся на расстоянии E_{ps} радиуса одна от другой
- Объединить каждую группу соединенных основных точек в отдельный кластер
- Назначить каждую пограничную точку одному из кластеров, ассоциированных с ней основных точек



МО. Кластеризация.ipynb

Пример Кейса



BUND2.csv




Dataset info (rus).docx



K-means Z-score.ipynb



Presentation.pdf




K-means


Влияние нормализации на кластеры



До нормализации




После нормализации




- Согласно формуле евклидовой меры, переменная, имеющая большие значения, практически полностью доминирует над переменной с малыми значениями.
- Для решения этой проблемы используется **нормализация** исходных данных.

ВИЗУАЛИЗАЦИЯ РЕЗУЛЬТАТОВ КЛАСТЕРИЗАЦИИ



2D



3D

ВИЗУАЛИЗАЦИЯ РЕЗУЛЬТАТОВ КЛАСТЕРИЗАЦИИ




nD?

ВИЗУАЛИЗАЦИЯ РЕЗУЛЬТАТОВ КЛАСТЕРИЗАЦИИ




Cluster characteristics: Feature means per cluster




nD?

ВИЗУАЛИЗАЦИЯ РЕЗУЛЬТАТОВ КЛАСТЕРИЗАЦИИ



nD?

ВИЗУАЛИЗАЦИЯ РЕЗУЛЬТАТОВ КЛАСТЕРИЗАЦИИ



nD?



Основное, что надо знать по этой теме

1. Метрика расстояния
2. K-means\DBSCAN – принцип, плюсы-минусы, применение
3. Правило локтя
4. Силуэт
5. График в параллельных координатах

ПРАКТИКА. КЛАСТЕРИЗАЦИЯ



<https://github.com/vxuv/ratemyprofessor-dataset/blob/main/README.md>

```
URL = "https://media.githubusercontent.com/media/vxuv/ratemyprofessor-dataset/main/reviews.csv"
```

```
# nrows=10000 – читаем только первые 10 000 строк, не трогая весь файл (1.36 ГБ)  
df = pd.read_csv(URL, nrows=10000, on_bad_lines='skip')
```

```
print("Размер датафрейма:", df.shape)  
df.head()
```

Для практики оставляем только:

```
['difficulty', 'would_take_again', 'for_credit']
```

ПРАКТИКА. КЛАСТЕРИЗАЦИЯ



Для практики оставляем только:

```
['difficulty', 'would_take_again', 'for_credit']
```

difficulty

Что это. Сложность курса по мнению студента.

would_take_again

Что это. Готовность студента снова пойти к этому преподавателю.

for_credit

Что это. Брал ли студент этот курс за зачёт/кредит (обязательный) или для интереса.

ПРАКТИКА. КЛАСТЕРИЗАЦИЯ



1. Читаем данные (пример кода выше)
2. Удаляем лишние столбцы
3. Выбираем оптимальное число кластеров
4. Строим кластеризацию
5. Строим график в параллельных координатах



<https://disk.yandex.ru/d/jg95HhqAUr13mw>

ПРАКТИКА. КЛАСТЕРИЗАЦИЯ



#	Столбец	Тип	Роль в K-Means	Ключевые сложности
1	id	ID	✗ не использовать	случайный номер
2	first_name	текст	✗ (только для groupby)	пропуски, высокая кардинальность
3	last_name	текст	✗ (только для groupby)	пропуски, регистр
4	Title	категория	✓ one-hot	дисбаланс классов
5	Quality	число 1–5	✓ ✓ ключевой	проверить 0.0
6	Difficulty	число 1–5	✓ ✓ ключевой	—
7	Tags	текст-мультиметка	✓ ✓ через CountVectorizer	пропуски, размерность
8	Comment	свободный текст	✓ через TF-IDF / эмбединги	шум, язык, длина
9	Date	дата	⚠ производные (год, семестр)	форматы
10	emotional_label	категория	✓ one-hot или валидация	ML-ошибки
11	Class	текст	⚠ предметная область	высокая кардинальность
12	for_credit	бинарный	✓	нормализация
13	Attendance	категория	✓ one-hot	опечатка в имени
14	would_take_again	% / бинарный	✓ ✓ сильный	формат %/Yes/No
15	Grade	категория	✓ порядковый маппинг	«Not sure yet»
16	`			